

Desafio 2 — Ativação e inicialização

GBC073 Inteligência Computacional, UFU / Diego de Miranda

ESCOLHA

f = LeakyReLU(0,1)

Nunca satura e nunca “morre”: sempre deixa passar um pouco de sinal e de gradiente, mesmo para entrada negativa.

INICIALIZAÇÃO

$$s^2 = 2 / (\text{fan_in} \cdot (1 + a^2))$$

com $a = 0,1 \rightarrow s^2 \approx 1,980 / \text{fan_in}$ (quase idêntico a He: $2/\text{fan_in}$)

POR QUÊ


Para uma pré-ativação calibrada $z \sim N(0,1)$ e $f_a(z) = z$ se $z \geq 0$, $a \cdot z$ se $z < 0$:

$$E[f_a(z)^2] = 0,5(1+a^2) \Rightarrow s^2 = 2 / (\text{fan_in}(1+a^2))$$

Com $a=0$ essa conta vira exatamente He — a variância inicial é quase a mesma. A diferença está na ativação: ReLU puro zera unidades negativas camada após camada, encolhendo o fan_in efetivo com a profundidade; LeakyReLU nunca zera, então a variância calibrada se sustenta até a camada 48.

Camada de logits: desvio $\times 0,5$, pois não há ativação depois dela.

VARIÂNCIA DA PRÉ-ATIVAÇÃO POR CAMADA (L = 48)



tanh cai a zero em poucas camadas; LeakyReLU(0,1) e ReLU+He permanecem próximos da referência ideal (var = 1) até a camada 48.

COMPARAÇÃO ENTRE CANDIDATOS

candidato	L = 48	acc. L = 16
tanh + U(−0,05, 0,05)	variância some	0,12
ReLU + He	estável	0,41
SELU + LeCun	diverge (NaN)	—
GELU / SiLU calibrados	diverge / explode	0,58 / —
LeakyReLU(0,1) — escolha	estável	0,59